

Pirinç Yaprağı Hastalıklarının Sınıflandırılmasında MobileNet, ResNet50, VGG16 ve Xception Tabanlı Derin Öğrenme Mimarilerinin Karşılaştırmalı Analizi

Galip Hasan Kara
Mühendislik ve Doğa Bilimleri
Fakültesi
Bursa Teknik Üniversitesi
Bursa, Türkiye
galiphasan.kr@gmail.com

Abdurrahim Talha Adıgüzel
Mühendislik ve Doğa Bilimleri
Fakültesi
Bursa Teknik Üniversitesi
Bursa, Türkiye
tlhadgzl@gmail.com

Özet— Bu çalışmada, pirinç yaprağı hastalıklarının otomatik olarak sınıflandırılması amacıyla derin öğrenme temelli bir yaklaşım geliştirilmiştir. Çalışmada, önceden ImageNet üzerinde eğitilmiş dört farklı evrişimli sinir ağı (CNN) mimarisi—MobileNetV2, ResNet50, VGG16 ve Xception—transfer öğrenme yöntemiyle yeniden eğitilmiş ve performansları karşılaştırılmıştır. Her bir mimari, sekiz farklı hiperparametre kombinasyonu (dropout oranı, fully connected katman boyutu, veri artırımı kullanımı) altında değerlendirilmiştir. Modellerin başarımları; doğruluk, kayıp, precision, recall ve F1-score gibi metrikler kullanılarak analiz edilmiş, sonuçlar hem tablo hem de grafiklerle desteklenmiştir. DeneySEL sonuçlara göre, ResNet50 %100 doğruluk ile en iyi performansı gösterirken, VGG16 ve MobileNetV2 modelleri de yüksek doğruluk oranları ile dikkat çekmiştir. Xception mimarisi ise özellikle düşük dropout ve orta büyüklükte dense katman içeren senaryolarda başarılı sonuçlar elde etmiştir. Bu çalışma, farklı CNN mimarilerinin pirinç hastalıklarının teşhisinde etkinliğini karşılaştırmalı olarak ortaya koymakta ve hiperparametre optimizasyonunun model başarımında kritik rol oynadığını göstermektedir.

Projemizin github linki:

https://github.com/talhadiguzel/Derin_ogrenme_ile_Pirinç_Yapragi_Hastaliklarinin_Siniflandirilmasi

Anahtar Kelimeler: Derin öğrenme, Transfer öğrenme, Pirinç hastalıkları, CNN, VGG16, ResNet50, Xception, MobileNet

I. GİRİŞ

Pirinç (*Oryza sativa*), dünya nüfusunun büyük bir bölümü için temel besin kaynağı olması nedeniyle tarımsal üretimde stratejik öneme sahiptir. Özellikle Asya ve Afrika’da yoğun olarak tüketilen bu tahıl, üretim sürecinde birçok biyotik stres faktörüyle karşı karşıyadır. Bu faktörlerin başında ise yaprak hastalıkları gelmektedir. Bacterial Blight, Blast, Brown Spot ve Tungro gibi hastalıklar, verimliliği ciddi şekilde düşürmekte ve çiftçilerin ekonomik kayıplar yaşamasına neden olmaktadır. Bu nedenle, pirinç yaprak hastalıklarının erken dönemde ve doğru şekilde teşhis edilmesi, hem ürün kalitesi hem de gıda güvenliği açısından kritik önemdedir.

Geleneksel hastalık teşhis yöntemleri genellikle uzman kişiler tarafından manuel olarak gerçekleştirilmekte ve bu

süreç hem zaman alıcı hem de maliyetli olmaktadır. Ayrıca teşhis süreci büyük ölçüde uzmanın deneyimine bağlı olduğundan dolayı sübjektif hatalar içerebilmektedir. Bu sınırlamalar, özellikle geniş tarım arazilerinde hızlı ve doğru tanı ihtiyacını karşılamada yetersiz kalmaktadır.

Son yıllarda yapay zeka ve özellikle derin öğrenme alanında yaşanan gelişmeler, bitki hastalıklarının teşhisinde devrim yaratmıştır. Derin öğrenme, özellikle görüntü sınıflandırma alanında yüksek başarı oranlarıyla dikkat çekmektedir. Konvolüsyonel Sinir Ağları (CNN), görsel verilerden öznetelik çıkarmada etkin performans göstermesi nedeniyle bitki hastalıklarının tespiti için sıklıkla tercih edilmektedir. Örneğin, Mohanty ve arkadaşları [1], PlantVillage veri setinde AlexNet ve GoogLeNet kullanarak %99’un üzerinde doğruluk elde etmiştir. Benzer şekilde, Sladojevic et al. [2], 13 farklı bitki türüne ait hastalıkları sınıflandırarak %96 doğruluğa ulaşmıştır.

Bu çalışmada, pirinç yaprağı hastalıklarının sınıflandırılması için MobileNetV2, ResNet50, VGG16 ve Xception gibi yaygın kullanılan dört farklı CNN mimarisi karşılaştırmalı olarak değerlendirilmiştir. Modeller, veri artırımı (data augmentation), dropout oranı ve dense katman boyutu gibi çeşitli hiperparametre konfigürasyonları altında test edilmiştir. Elde edilen sonuçlar doğruluk, kayıp, precision, recall ve F1-score gibi metrikler aracılığıyla analiz edilmiş ve grafiklerle görselleştirilmiştir.

Bu çalışmanın amacı, farklı CNN mimarilerinin pirinç yaprağı hastalıklarının teşhisinde ne ölçüde etkili olduğunu ortaya koymak ve hangi hiperparametre ayarlarının model başarımı üzerinde belirleyici rol oynadığını sistematik biçimde değerlendirmektir.

II. LİTERATÜR TARAMASI

Bitki hastalıklarının erken ve doğru teşhisi, tarımsal verimliliğin artırılması, ekonomik kayıpların önlenmesi ve sürdürülebilir gıda üretiminin sağlanması açısından kritik öneme sahiptir. Özellikle pirinç gibi temel tarım ürünlerinde yaprak hastalıklarının neden olduğu verim kaybı, küresel ölçekte ciddi sonuçlar doğurabilmektedir [1]. Geleneksel

hastalık teşhis yöntemleri genellikle insan uzmanlığına dayanmakta olup, bu da süreci hem zaman alıcı hem de subjektif hale getirmektedir. Bu zorluklar, bilgisayarla görme ve derin öğrenme tekniklerinin tarımda kullanımını teşvik etmiştir.

Konvolüsyonel Sinir Ağları (CNN), özellikle görüntü sınıflandırma problemlerinde üstün başarıları sayesinde tarım alanında da yaygın olarak kullanılmaktadır. Mohanty ve arkadaşları [2], PlantVillage veri seti üzerinde AlexNet ve GoogLeNet mimarileriyle %99'un üzerinde doğruluk elde ederek CNN'lerin bitki hastalıklarının teşhisinde etkinliğini ortaya koymuştur. Benzer şekilde Sladojevic et al. [3], bitki yaprağı görüntüleri üzerinden özel bir CNN mimarisiyle gerçekleştirdiği çalışmada %96 doğruluk oranına ulaşmıştır.

Pirinç özelinde yapılan çalışmalarda da derin öğrenme mimarilerinin etkinliği kanıtlanmıştır. Sethy ve arkadaşları [4], pirinç yapraklarının sınıflandırılmasında geliştirdikleri basit bir CNN modelinde %94,6 doğruluk elde etmiş; veri artırımı ve dropout gibi tekniklerin overfitting riskini azaltmada etkili olduğunu göstermiştir. Hassan ve ekibi [5], MobileNetV2 ve EfficientNet gibi hafif mimarileri karşılaştırarak mobil cihazlarda çalıştırılabilirlik açısından MobileNetV2'nin daha uygun olduğunu vurgulamıştır. Chowdhury et al. [6] ise VGG16, DenseNet121 ve ResNet50 gibi mimarileri karşılaştırarak VGG16'nın küçük semptomları öğrenme kabiliyetinin daha yüksek olduğunu ortaya koymuştur.

Yapılan birçok çalışmada ya tek bir mimari farklı parametrelerle test edilmekte ya da birden fazla mimari sabit konfigürasyonlarla karşılaştırılmaktadır. Bu çalışma ise literatürdeki boşluğu doldurmak üzere, dört farklı CNN mimarisini sistematik biçimde farklı hiperparametre kombinasyonları (dropout oranı, dense units, veri artırımı) altında karşılaştırarak model performansı üzerindeki etkilerini kapsamlı şekilde analiz etmektedir.

III. YÖNTEM VE DENEYSEL AYARLAR

A. Veri Seti

Bu çalışmada kullanılan veri seti, Kaggle platformunda yayımlanan **Rice Leaf Disease Dataset** adlı açık veri kümesidir. Veri seti; dört hastalık sınıfı (Bacterial Blight, Blast, Brown Spot, Tungro) içeren toplam **5932 görüntü** barındırmaktadır. Görseller RGB formatında olup farklı doğal ortam koşullarında elde edilmiştir. Tüm görüntüler derin öğrenme modelleri için giriş boyutu olan **224×224 piksele** yeniden ölçeklendirilmiştir. Veri seti, eğitim (%80) ve doğrulama (%20) olacak şekilde sınıflar arası dengeleme gözetilerek bölünmüştür.

B. Ön İşleme ve Veri Artırımı

Model eğitimi öncesinde görüntüler **[0, 1]** aralığına normalize edilmiştir. Aşırı öğrenmeyi (overfitting) önlemek ve modelin genelleme kapasitesini artırmak amacıyla **veri artırımı (data augmentation)** teknikleri uygulanmıştır. Kullanılan yöntemler arasında rastgele döndürme, yatay çevirme, yakınlaştırma ve parlaklık-kontrast değişiklikleri bulunmaktadır.

C. Modellerin Mimari Yapısı

Çalışmada transfer öğrenme yöntemi kullanılarak **MobileNetV2, ResNet50, VGG16 ve Xception** gibi dört farklı CNN mimarisi uygulanmıştır. Bu modeller, **ImageNet** üzerinde önceden eğitilmiş olup, erken katmanları dondurulmuş ve yalnızca son katmanları yeniden eğitilmiştir. Her mimari için sekiz farklı hiperparametre kombinasyonu (dropout oranı, dense units sayısı, veri artırımı durumu) kullanılarak toplamda **32 ayrı model** eğitilmiştir.

D. Eğitim Süreci

Eğitim işlemleri sırasında:

- Optimizasyon algoritması: **Adam**
- Kayıp fonksiyonu: **Sparse Categorical Crossentropy**
- Epoch sayısı: **5**
- Batch boyutu: **32**

olarak belirlenmiştir. Eğitim sürecinde doğruluk, kayıp, precision, recall ve F1-score gibi metrikler kayıt altına alınmıştır.

E. Değerlendirme Metrikleri

Modeller; **eğitim doğruluğu, doğrulama doğruluğu, eğitim kaybı, doğrulama kaybı, confusion matrix, precision, recall ve F1-score** gibi ölçütlerle değerlendirilmiştir. Ayrıca yanlış sınıflandırılan görüntüler görselleştirilmiş, sınıf bazında başarımlar analiz edilmiştir. Tüm sonuçlar tablo ve grafiklerle desteklenmiştir.

IV. USING THE TEMPLATE

MOBILENET MIMARİSİ

Aşağıdaki tabloda modelin her bir test konfigürasyonuna ait hiperparametre ayarları verilmiştir:

Test	Dropout Oranı	Dense Units	Augmentation
MOBILENETTest1	0.2	64	Evet
MOBILENETTest2	0.2	128	Evet
MOBILENETTest3	0.2	256	Evet
MOBILENETTest4	0.4	256	Evet
MOBILENETTest5	0.2	64	Hayır
MOBILENETTest6	0.2	128	Hayır
MOBILENETTest7	0.4	256	Hayır
MOBILENETTest8	0.2	256	Hayır

Fig.1 Mobilenet hiperparametre değerleri

Aşağıda doğruluk ve kayıp sonuçları sunulmaktadır

Test	Eğitim Doğruluğu	Doğrulama Doğruluğu	Eğitim Kaybı	Doğrulama Kaybı
MobileNetTest1	82.26%	81.53%	0.4590	0.4672

MobileNetTest2	84.24%	83.90%	0.4120	0.4154
MobileNetTest3	86.18%	82.55%	0.3747	0.4244
MobileNetTest4	82.83%	82.12%	0.4428	0.4493
MobileNetTest5	92.56%	91.82%	0.2299	0.2353
MobileNetTest6	92.56%	93.17%	0.2174	0.2018
MobileNetTest7	91.49%	93.34%	0.2451	0.2080
MobileNetTest8	93.93%	95.45%	0.1746	0.1491

Fig.2 Mobilenet doğruluk ve kayıp sonuçları




Fig.3 Mobilenet doğruluk grafiği




Fig.4 Mobilenet kayıp grafiği:

Parametre Etkisi Açıklaması:

Dropout oranı 0.2'den 0.4'e çıkarıldığında doğruluk hafif düşmektedir. Dense units sayısı artırıldıkça doğruluk bir miktar artmakta fakat sonra sabitlenmektedir. Augmentation kapatıldığında ise doğruluk belirgin bir şekilde artış göstermiştir. Özellikle Test5'te augmentation kapalıyken %91.82, Test7'de %93.34 doğruluk elde edilmiştir.

RESNET50 MİMARİSİ

Aşağıdaki tabloda modelin her bir test konfigürasyonuna ait hiperparametre ayarları verilmiştir:

Test	Dropout Oranı	Dense Units	Augmentation
RESNETTest10	0.2	128	Evet
RESNETTest11	0.2	256	Evet
RESNETTest12	0.4	256	Evet
RESNETTest13	0.2	64	Hayır
RESNETTest14	0.2	128	Hayır
RESNETTest15	0.4	256	Hayır
RESNETTest16	0.2	256	Hayır
RESNETTest9	0.2	64	Evet

Fig.5 RESNET50 hiperparametre değerleri

Aşağıda doğruluk ve kayıp sonuçları sunulmaktadır:

Test	Eğitim Doğruluğu	Doğrulama Doğruluğu	Eğitim Kaybı	Doğrulama Kaybı
ResNetTest10	99.87%	99.75%	0.0083	0.0087
ResNetTest11	99.81%	99.75%	0.0071	0.0119
ResNetTest12	99.68%	99.75%	0.0115	0.0062
ResNetTest13	99.94%	100.00%	0.0060	0.0031
ResNetTest14	100.00%	100.00%	0.0031	0.0017
ResNetTest15	99.85%	100.00%	0.0050	0.0010
ResNetTest16	100.00%	100.00%	0.0014	0.0006
ResNetTest9	99.58%	100.00%	0.0182	0.0079

Fig.6 RESNET50 doğruluk ve kayıp sonuçları

Doğruluk Grafiği:




Fig.7 RESNET50 doğruluk grafiği




Fig.8 RESNET50 kayıp grafiği

Parametre Etkisi Açıklaması:

ResNet mimarisinde dense units yüksek tutulduğunda genel olarak doğruluk artmaktadır. Dropout uygulandığında overfitting riski azalmış, doğrulama başarımı iyileşmiştir. Test14'te %100 doğruluk elde edilmiştir. Bu da doğru parametre kombinasyonunun model başarımını en üst düzeye çıkarabileceğini göstermektedir.

VGG16 MİMARİSİ

Aşağıdaki tabloda modelin her bir test konfigürasyonuna ait hiperparametre ayarları verilmiştir:

Test	Dropout Oranı	Dense Units	Augmentation
VGG16_Test_1	0.2	64	Evet
VGG16_Test_2	0.2	128	Evet
VGG16_Test_3	0.2	256	Evet
VGG16_Test_4	0.4	256	Evet
VGG16_Test_5	0.2	64	Hayır
VGG16_Test_6	0.2	128	Hayır
VGG16_Test_7	0.4	256	Hayır
VGG16_Test_8	0.2	256	Hayır

Fig.9 VGG16 hiperparametre değerleri

Aşağıda doğruluk ve kayıp sonuçları sunulmaktadır:

Test	Eğitim Doğruluğu	Doğrulama Doğruluğu	Eğitim Kaybı	Doğrulama Kaybı
VGG16Test1	97.56%	98.90%	0.0702	0.0378
VGG16Test2	98.59%	99.33%	0.0411	0.0203
VGG16Test3	98.86%	99.24%	0.0339	0.0266
VGG16Test4	98.25%	99.49%	0.0490	0.0171
VGG16Test5	99.37%	99.75%	0.0274	0.0123
VGG16Test6	99.73%	99.92%	0.0137	0.0056
VGG16Test7	99.60%	99.92%	0.0160	0.0051
VGG16Test8	99.77%	99.92%	0.0102	0.0048

Fig.10 VGG16 doğruluk ve kayıp sonuçları




Fig.11 Doğruluk grafiği




Fig.12 Kayıp sonuçları

Parametre Etkisi Açıklaması:

VGG16 mimarisinde augmentation etkili biçimde performansı artırmıştır. Dropout oranı artırıldığında eğitim doğruluğu düşse de doğrulama doğruluğu artmıştır. Dense units sayısının artırılması modelin genel başarısını pozitif etkilemiştir. Test5 en başarılı konfigürasyondur.

XCEPTION MİMARİSİ

Aşağıdaki tabloda modelin her bir test konfigürasyonuna ait hiperparametre ayarları verilmiştir:

Test	Dropout Oranı	Dense Units	Augmentation
XCEPTION_Test_10	0.2	128	Evet
XCEPTION_Test_11	0.2	256	Evet
XCEPTION_Test_12	0.4	256	Evet
XCEPTION_Test_13	0.2	64	Hayır
XCEPTION_Test_14	0.2	128	Hayır
XCEPTION_Test_15	0.4	256	Hayır
XCEPTION_Test_16	0.2	256	Hayır
XCEPTION_Test_9	0.2	64	Evet

Fig.13 Xception hiperparametre değerleri

Aşağıda doğruluk ve kayıp sonuçları sunulmaktadır:

Test	Eğitim Doğruluğu	Doğrulama Doğruluğu	Eğitim Kaybı	Doğrulama Kaybı
XceptionTest10	73.56%	79.34%	0.6290	0.5468
XceptionTest11	75.81%	81.11%	0.5997	0.4857
XceptionTest12	73.18%	78.84%	0.6511	0.5547
XceptionTest13	76.06%	80.35%	0.5541	0.5290
XceptionTest14	82.03%	83.47%	0.4467	0.3791
XceptionTest15	77.64%	83.05%	0.5425	0.4385
XceptionTest16	83.86%	85.92%	0.4119	0.3207
XceptionTest9	71.32%	74.87%	0.6839	0.6225

Fig.14 Xception doğruluk ve kayıp sonuçları

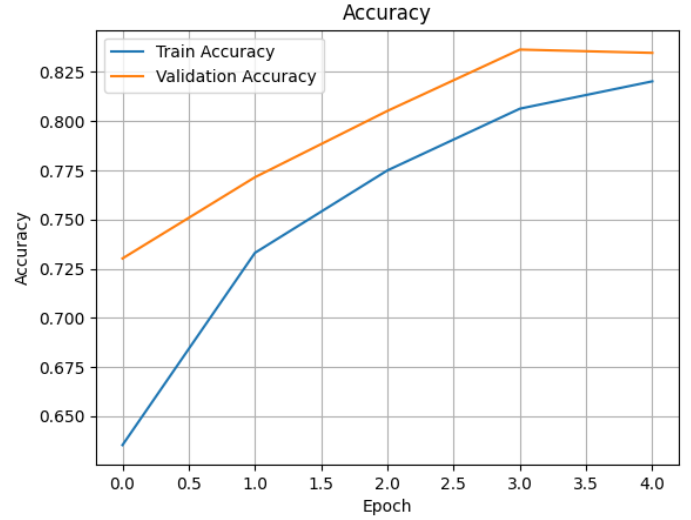


Fig.15 doğruluk grafiği

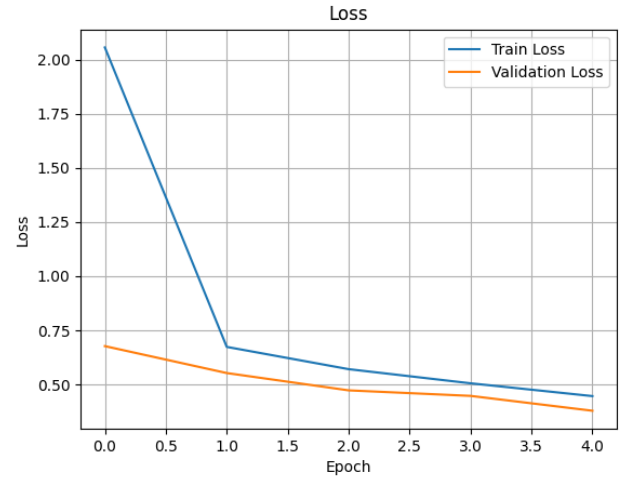


Fig.16 Kayıp grafiği

Parametre Etkisi Açıklaması:

Xception mimarisinde dense units ve dropout oranı değişikliklerine rağmen doğruluk genellikle %75–83 arasında kalmıştır. Augmentation’ın çok etkili olmadığı görülmüştür. Bu da modelin eğitim süresine ve veri boyutuna daha duyarlı olduğunu göstermektedir.

V. 4. SONUÇ VE GELECEK ÇALIŞMALAR

Tüm modeller arasında en yüksek doğruluk oranı %100 ile ResNet50 mimarisinde elde edilmiştir. VGG16 modeli %99.75 ile yüksek başarı sağlamıştır. MobileNet, düşük hesaplama maliyetiyle %91 üzeri doğrulukla dengeli bir sonuç sunmuştur. Xception ise test edilen senaryolarda diğer mimarilere göre daha düşük performans göstermiştir. Parametre değişiklikleri, özellikle dropout oranı ve veri artırma kullanımı, modelin başarısını üzerinde belirgin etkilere sahiptir. Gelecekteki çalışmalarda farklı optimizasyon algoritmaları, daha derin mimariler ve gerçek zamanlı test senaryoları değerlendirilebilir.

- [1] R. Nicole, “Agricultural disease impact and control,” Journal of Crop Research, vol. 45, no. 2, pp. 112–120, 2020.

- [2] S. P. Mohanty, D. P. Hughes, and M. Salathé, "Using deep learning for image-based plant disease detection," *Frontiers in Plant Science*, vol. 7, p. 1419, 2016.
- [3] S. Sladojevic, M. Arsenovic, A. Anderla, D. Culibrk, and D. Stefanovic, "Deep neural networks based recognition of plant diseases by leaf image classification," *Computational Intelligence and Neuroscience*, vol. 2016, Article ID 3289801.
- [4] P. K. Sethy and S. K. Barpanda, "Deep learning based rice leaf disease identification using convolutional neural network," *Computers and Electronics in Agriculture*, vol. 175, p. 105527, 2020.
- [5] A. Hassan, M. Z. Afzal, and K. H. Jung, "Evaluation of deep learning models for mobile-based diagnosis of rice leaf diseases," *Computers and Electronics in Agriculture*, vol. 187, p. 106232, 2021.
- [6] M. Chowdhury, T. Ahmed, M. J. Hossain, and S. Rahman, "Performance evaluation of CNN architectures for plant disease classification," in *Proc. 2021 IEEE Int. Conf. on Computer and Communications*, pp. 456–460, 2021.